

Metodología Híbrida para la Proyección de la Demanda de Potencia y Energía Eléctrica en Ecuador: Un Enfoque Integrado Bottom-Up y Top-Down

Sección 1: Un Marco Estratégico para la Proyección de la Demanda Nacional en Ecuador

1.1. Introducción: El Imperativo de una Arquitectura de Proyección Híbrida

La planificación del sector eléctrico en una economía en desarrollo como la de Ecuador exige un enfoque de proyección de la demanda que trascienda los métodos monolíticos tradicionales. Las metodologías puramente "top-down" (de arriba hacia abajo), que desagregan pronósticos macroeconómicos, a menudo carecen de la granularidad necesaria para la planificación operativa y no logran capturar los cambios estructurales a nivel de consumidor. Por otro lado, los enfoques puramente "bottom-up" (de abajo hacia arriba), que agregan proyecciones desde los niveles más bajos de consumo, pueden acumular errores y desalinearse de los objetivos estratégicos nacionales a largo plazo.¹ La creciente complejidad del sistema eléctrico, impulsada por la electrificación de nuevos sectores, la penetración de energías renovables y la evolución de los patrones de consumo, hace que estos enfoques aislados sean insuficientes para una planificación robusta.³

Este documento presenta una metodología de proyección de demanda híbrida, diseñada específicamente para el contexto ecuatoriano. El marco propuesto integra la precisión granular de un motor de pronóstico *bottom-up* con la coherencia estratégica de escenarios *top-down* que actúan como techos de control. La componente *bottom-up* aprovecha la

riqueza de los datos históricos disponibles —desde la facturación mensual por grupo de consumo y empresa distribuidora hasta los datos horarios en puntos de entrega— para generar pronósticos detallados a corto y mediano plazo, esenciales para la planificación operativa, la gestión de la red y la optimización del despacho.¹ Simultáneamente, la componente

top-down establece las proyecciones de largo plazo, asegurando que el crecimiento de la demanda esté anclado en los objetivos de política energética nacional, las proyecciones macroeconómicas y los planes de inversión, como los delineados en el Plan Maestro de Electricidad 2023-2032.⁴

El núcleo innovador de esta metodología es un proceso de reconciliación iterativo, concebido como un mecanismo de "avance-retroceso" (*forward-backward*), análogo a los algoritmos de flujo de carga en redes de distribución. Este proceso no es simplemente un ajuste matemático para forzar la coherencia; representa un diálogo cuantitativo entre las tendencias de consumo observadas a nivel micro y las metas de política energética definidas a nivel macro.⁷ La convergencia entre ambos enfoques produce un conjunto de proyecciones que no solo son matemáticamente consistentes en todas las jerarquías (por sector, por empresa, por etapa del sistema), sino que también son estratégicamente relevantes y operativamente accionables. Este enfoque híbrido permite modelar cambios estructurales y variaciones a nivel de base, al tiempo que se ajusta a los impulsores fundamentales del sistema, ofreciendo una visión completa y robusta del futuro de la demanda eléctrica en Ecuador.⁷

La solicitud de un modelo *bottom-up* con un techo *top-down* refleja una tensión fundamental en la planificación energética: el equilibrio entre la realidad operativa y la ambición estratégica. Los pronósticos *bottom-up*, arraigados en patrones de consumo históricos, representan "lo que es probable que suceda" si las tendencias pasadas continúan. En contraste, los escenarios *top-down*, derivados de planes maestros y objetivos de política, representan "lo que se desea que suceda", como la electrificación acelerada del transporte o la mejora de la eficiencia industrial. La simple agregación de los pronósticos granulares rara vez coincidirá con los objetivos nacionales, creando una brecha de planificación. El proceso de reconciliación iterativo propuesto en esta metodología es el mecanismo que resuelve esta tensión. Al forzar una alineación cuantitativa, los ajustes aplicados a los pronósticos *bottom-up* representan el "esfuerzo" o el "cambio" requerido a nivel granular para alcanzar las metas nacionales. Por lo tanto, el resultado final no es solo una proyección coherente, sino una hoja de ruta cuantitativa que identifica qué sectores deben desviarse más de sus trayectorias históricas para materializar la visión estratégica del país, convirtiéndose en una poderosa herramienta analítica para los responsables de la formulación de políticas.

1.2. Filosofía Metodológica: Equilibrando Precisión, Interpretabilidad y

Relevancia Política

La selección de un modelo de proyección no debe basarse únicamente en la métrica de precisión. Un marco de planificación nacional eficaz debe equilibrar tres pilares fundamentales: precisión predictiva, interpretabilidad del modelo y relevancia para la formulación de políticas. Los modelos de alta complejidad, como las redes neuronales de aprendizaje profundo (por ejemplo, LSTM, CNN-LSTM), han demostrado una precisión superior en la captura de patrones no lineales complejos en series de tiempo de demanda eléctrica.⁸ Sin embargo, su naturaleza de "caja negra" puede ser un obstáculo significativo en un entorno de política pública, donde es crucial entender

por qué el modelo predice un resultado determinado para justificar decisiones de inversión multimillonarias y ganar la confianza de las partes interesadas.¹⁰

Por otro lado, los modelos estadísticos y econométricos tradicionales, como SARIMAX y los modelos de regresión multivariante, ofrecen una alta interpretabilidad. Sus parámetros tienen un significado económico o físico directo (por ejemplo, la elasticidad de la demanda con respecto al precio o al PIB), lo que facilita el análisis de sensibilidad y la discusión de escenarios con actores no técnicos.¹⁰ Aunque pueden tener una precisión predictiva limitada en sistemas altamente no lineales, su transparencia es invaluable para el debate político y la planificación estratégica.¹⁰

La metodología propuesta adopta una filosofía pragmática y modular que busca lo mejor de ambos mundos. No prescribe un único modelo para todas las tareas, sino que establece una arquitectura flexible donde diferentes tipos de modelos se aplican en los contextos para los que son más adecuados. Se utilizarán modelos estadísticos robustos como SARIMAX para las proyecciones de corto y mediano plazo a nivel granular, donde la estacionalidad y los factores exógenos son dominantes y la interpretabilidad es clave para los operadores. Para las proyecciones de largo plazo, se emplearán modelos econométricos que vinculan explícitamente la demanda de energía con sus impulsores fundamentales (PIB, población, precios), permitiendo una simulación de escenarios coherente con las proyecciones macroeconómicas nacionales.¹² Los modelos de aprendizaje profundo se consideran como herramientas avanzadas que pueden ser integradas en el marco para tareas específicas, como modelar los componentes residuales no lineales de los pronósticos base o para proyecciones a muy corto plazo donde la precisión es primordial.¹⁴

Este diseño modular garantiza que el sistema de proyección pueda evolucionar con el tiempo. A medida que se disponga de nuevos datos (por ejemplo, datos de medidores inteligentes a gran escala) o que las necesidades de proyección cambien, los modelos específicos dentro de la arquitectura pueden ser actualizados o reemplazados sin comprometer la integridad del marco general de agregación y reconciliación. Esta flexibilidad asegura la longevidad y

relevancia continua del sistema de proyección como una herramienta central para la planificación del sector eléctrico ecuatoriano.

Sección 2: Arquitectura de Datos y Preprocesamiento para un Modelado Robusto

2.1. Inventario y Consolidación de Datos

La base de cualquier sistema de proyección fiable es una arquitectura de datos bien estructurada y centralizada. El primer paso metodológico es realizar un inventario exhaustivo de todas las fuentes de datos disponibles y consolidarlas en un repositorio único y coherente, que servirá como la "única fuente de verdad" para todos los análisis posteriores. Según la información proporcionada, los activos de datos clave para Ecuador incluyen:

1. **Datos de Facturación Mensual (1999-presente):** Energía facturada (kWh) por grupo de consumo (Residencial, Comercial, Industrial, Alumbrado Público, Otros) y por empresa distribuidora. Este es el conjunto de datos de mayor extensión temporal y constituye la columna vertebral para el modelado econométrico de largo plazo.
2. **Datos de Demanda Diaria del Sistema:** Potencia (MW) y energía (MWh) total a nivel de cada empresa distribuidora. Proporciona una visión agregada de la dinámica de la demanda a una frecuencia más alta.
3. **Datos Horarios en Puntos de Entrega:** Demanda horaria (MW, MWh) en las interfaces entre transmisión y distribución. Estos datos son cruciales para la generación de perfiles de carga típicos.
4. **Datos de Despacho Horario de Generación:** Potencia despachada (MW) por tecnología de generación. Útil para análisis de coherencia y para entender la dinámica de la oferta.
5. **Datos Horarios en Alimentadores (Potencial):** Demanda horaria en la cabecera de los alimentadores de las subestaciones de distribución. Si se obtiene, este dato ofrece el nivel más alto de granularidad para el análisis de perfiles de carga y la estimación de pérdidas en distribución.

La consolidación implica la creación de una base de datos relacional o un lago de datos donde todas estas fuentes se almacenen con una estructura de tiempo estandarizada (por ejemplo, usando marcas de tiempo UTC) y claves de relación consistentes (códigos de empresa distribuidora, identificadores de sector de consumo, etc.). Este paso es fundamental

para garantizar la integridad y la facilidad de acceso a los datos durante todo el ciclo de vida del proyecto.

2.2. Limpieza de Datos y Mejora de la Calidad

Los datos operativos del sector eléctrico rara vez son perfectos y su uso en bruto puede llevar a modelos sesgados y pronósticos poco fiables. Por lo tanto, un pipeline de preprocesamiento riguroso es un prerrequisito no negociable.¹⁵ Este proceso debe ser sistemático, documentado y reproducible, aplicando técnicas específicas según la naturaleza y la frecuencia de cada conjunto de datos.

- **Imputación de Valores Faltantes:** La estrategia de imputación debe adaptarse a la granularidad de los datos.
 - Para los datos de **facturación mensual**, donde la estacionalidad es fuerte pero la autocorrelación a corto plazo es menos crítica, los valores faltantes pueden ser imputados utilizando técnicas como la interpolación lineal o cúbica, o métodos más robustos como la descomposición estacional (STL) seguida de la imputación de la componente residual.¹⁷
 - Para los **datos horarios y diarios**, donde la estructura temporal es fundamental, la simple interpolación puede distorsionar los patrones. Se recomiendan métodos más sofisticados. La imputación basada en K-Vecinos Más Cercanos (KNN) encuentra días o horas con patrones similares en el pasado y utiliza sus valores para rellenar los huecos. Alternativamente, se pueden entrenar modelos de series de tiempo (como ARIMA o un modelo estacional simple) con los datos existentes para predecir y rellenar los valores faltantes, preservando así la estructura de autocorrelación y estacionalidad de los datos.¹⁷
- **Detección y Tratamiento de Valores Atípicos (Outliers):** Los valores atípicos pueden deberse a errores de medición, fallos en los equipos, ajustes de facturación retroactivos o eventos no recurrentes.
 - **Detección:** Se deben aplicar métodos estadísticos para identificar estos puntos. El método del Rango Intercuartílico (IQR) es robusto para datos no distribuidos normalmente. Para series de tiempo, el método de Z-score modificado (basado en la desviación absoluta mediana) es efectivo. Los valores que excedan un umbral predefinido (por ejemplo, $1.5 \times \text{IQR}$ o un Z-score de 3.5) se marcarán como posibles valores atípicos.¹⁵
 - **Tratamiento:** La eliminación simple de los valores atípicos no es aconsejable, ya que crea nuevos valores faltantes. La estrategia preferida es tratar los valores atípicos detectados como valores faltantes y aplicar las técnicas de imputación descritas anteriormente para reemplazarlos con valores más plausibles. Cada valor atípico significativo debe ser investigado para determinar su causa raíz; si corresponde a un

evento real (por ejemplo, una ola de calor extrema), puede ser retenido y modelado explícitamente con una variable exógena.

- **Extracción de Ruido:** Este paso implica la eliminación de datos que son físicamente imposibles o que son artefactos del sistema de recolección. Esto incluye valores de consumo negativos, códigos de error aleatorios en lugar de valores numéricos, y saltos o caídas abruptas que se sabe que son el resultado de cambios en la configuración del medidor en lugar de un cambio real en el consumo.¹⁷

2.3. Ingeniería de Características y Transformación de Datos

Una vez que los datos están limpios, el siguiente paso es enriquecerlos mediante la creación de nuevas variables (características o *features*) que ayuden a los modelos a capturar mejor los patrones de la demanda.

- **Descomposición de Series de Tiempo:** Es fundamental descomponer las series de tiempo de demanda en sus componentes subyacentes para entender su estructura. Se pueden utilizar métodos como promedios móviles, pero técnicas más avanzadas como la Descomposición Estacional de Series de Tiempo por Loess (STL) o el Análisis de Espectro Singular (SSA) son superiores para separar la **tendencia** (el crecimiento o decrecimiento a largo plazo), la **estacionalidad** (patrones anuales, semanales y diarios) y el **residuo** (ruido aleatorio).⁹ Esta descomposición no solo ayuda en la visualización y el entendimiento, sino que también puede mejorar el rendimiento del modelo al permitir que se modele cada componente por separado.
- **Integración de Variables Exógenas:** La demanda de electricidad está fuertemente influenciada por factores externos. Es crucial construir un conjunto de datos completo de variables predictoras, alineadas temporalmente con la serie de demanda:
 - **Datos Meteorológicos:** La temperatura es el predictor más importante. Se deben crear variables como Grados Día de Calefacción (HDD) y Grados Día de Refrigeración (CDD), que miden la desviación de la temperatura con respecto a una base de confort y tienen una relación más lineal con la demanda de climatización. Otras variables relevantes incluyen la humedad (que afecta la sensación térmica), la velocidad del viento (relevante para la demanda de calefacción y la generación eólica) y la radiación solar.
 - **Efectos de Calendario:** Se deben crear variables binarias (*dummy variables*) para capturar patrones recurrentes: día de la semana, mes del año, días festivos nacionales y locales (que a menudo tienen perfiles de consumo similares a los domingos), y eventos especiales que puedan impactar la demanda.
 - **Datos Macroeconómicos:** Para los modelos de largo plazo, es esencial incluir variables como el Producto Interno Bruto (PIB) nacional y sectorial, proyecciones de población, tasas de inflación, y las tarifas eléctricas promedio por sector. Estas

variables capturan los impulsores fundamentales del crecimiento de la demanda.¹¹

- **Escalado y Normalización de Datos:** Muchos algoritmos de aprendizaje automático, especialmente las redes neuronales como LSTM, requieren que las variables de entrada estén en una escala similar para un entrenamiento estable y eficiente. Se deben aplicar técnicas como el escalado Min-Max (que transforma los datos a un rango, por ejemplo,) o la estandarización (que transforma los datos para que tengan una media de 0 y una desviación estándar de 1) a todas las variables de entrada antes de alimentar el modelo.¹⁵

La implementación de un pipeline de preprocesamiento estandarizado y automatizado es crucial. Para gestionar esta complejidad de manera efectiva, se propone la siguiente tabla como una herramienta de planificación y documentación.

Tabla 1: Inventario de Datos y Estrategia de Preprocesamiento					
Fuente de Datos	Granularidad	Período	Variables Clave	Problemas de Calidad Identificados	Pipeline de Preprocesamiento Prescrito
Facturación Residencial - Distribuidora A	Mensual	1999-Presente	Energía (kWh), # Clientes	Valores faltantes (2002-2003), outliers por ajustes	1. Detección de outliers (IQR). 2. Imputación de faltantes/outliers (STL). 3. Ingeniería de características (HDD, CDD, PIB per cápita).

Facturación Industrial - Distribuidor a B	Mensual	1999-Prese nte	Energía (kWh), Potencia (kW)	Outliers esporádicos	1. Detección de outliers (Z-score modificado). 2. Imputación (interpolación). 3. Ingeniería de características (Índice de Producción Industrial, Precios).
Punto de Entrega PO1 - Sistema Nacional	Horaria	2015-Prese nte	Potencia (MW)	Faltantes por fallas de comunicación (bloques de 2-4 horas)	1. Imputación de faltantes (KNN o modelo ARIMA). 2. Creación de variables de calendario (hora, día de la semana, festivo). 3. Normalización (Min-Max).
Demanda Total - Distribuidor a C	Diaria	2010-Prese nte	Energía (MWh), Potencia Máx (MW)	Sin problemas mayores identificado	1. Ingeniería de características

				s	(variables meteorológicas diarias, día de la semana). 2. Descomposición de la serie (STL).
Alimentador S01-A01 (Potencial)	Horaria	N/A	Potencia (MW)	N/A	1. Limpieza inicial. 2. Imputación. 3. Normalización. 4. Creación de variables de calendario.

Esta tabla formaliza un plan de acción sistemático, asegurando que cada activo de datos sea tratado de manera consistente y apropiada, lo que es fundamental para la reproducibilidad y la fiabilidad de un modelo de proyección a nivel nacional que será mantenido y actualizado a lo largo del tiempo.

Sección 3: Caracterización de Patrones de Consumo a través de Perfiles de Carga

3.1. Justificación del Perfilado de Carga

Antes de intentar proyectar la demanda agregada, es imperativo comprender los patrones de comportamiento subyacentes de los diferentes grupos de consumidores. La facturación mensual informa *cuánta* energía se consume, pero no *cuándo* se consume. Esta dimensión

temporal es crítica para la planificación de la operación del sistema, la gestión de la demanda máxima y la evaluación de la necesidad de capacidad de generación. Los Perfiles de Carga Típicos (TLPs, por sus siglas en inglés) son representaciones estandarizadas de la forma característica del consumo de un segmento de clientes a lo largo de un período de tiempo, típicamente un día o una semana.²¹

La generación de TLPs cumple dos funciones esenciales dentro de este marco metodológico:

1. **Desagregación Temporal:** Permiten convertir la larga serie histórica de datos de facturación de energía mensual en series de tiempo de carga horaria estimada. Este proceso enriquece masivamente el conjunto de datos, creando una base de datos de alta frecuencia que es indispensable para el modelado detallado de corto y mediano plazo y para el cálculo preciso de los factores de carga y pérdida.²³
2. **Segmentación de Clientes:** El proceso de creación de TLPs es, en sí mismo, una poderosa técnica de segmentación de clientes basada en el comportamiento. Identifica grupos de consumidores con patrones de uso de energía similares, lo que permite un análisis más matizado y abre la puerta a aplicaciones más allá de la proyección, como el diseño de tarifas por tiempo de uso, programas de respuesta a la demanda y campañas de eficiencia energética dirigidas.²²

3.2. Metodología para la Generación de TLPs

Se propone una metodología de agrupamiento (*clustering*) no supervisado en varias etapas para generar un conjunto de TLPs representativos para cada sector de consumo principal (Residencial, Comercial, Industrial) a partir de los datos horarios disponibles (puntos de entrega o, idealmente, alimentadores).²⁴

- **Paso 1: Preparación y Normalización de Datos:**
 1. Se extraen los perfiles de carga diarios (vectores de 24 o 48 puntos) de la serie de tiempo horaria o semihoraria.
 2. Para centrarse en la **forma** del perfil de carga, independientemente de su magnitud (consumo total diario), cada perfil diario se normaliza. Un método común es dividir el valor de consumo de cada hora por el consumo medio diario. Esto asegura que perfiles con formas idénticas pero diferentes niveles de consumo sean tratados como similares por el algoritmo de agrupamiento.²²
- **Paso 2: Algoritmo de Agrupamiento (Clustering):**

Se utiliza un algoritmo de agrupamiento para agrupar los perfiles diarios normalizados en un número predefinido de clústeres. El algoritmo K-medias (K-means) es una elección común y robusta para esta tarea debido a su eficiencia computacional y su buen rendimiento demostrado en el perfilado de carga.²¹ El algoritmo agrupa los perfiles de

manera que se minimice la distancia (por ejemplo, la distancia euclidiana) entre cada perfil y el centroide (perfil medio) de su clúster asignado.

- **Paso 3: Selección del Número Óptimo de Clústeres:**

La elección del número de clústeres (k) es un paso crítico. Un valor de k demasiado bajo puede no capturar la diversidad de patrones de consumo, mientras que un valor demasiado alto puede crear clústeres redundantes y difíciles de interpretar. Se deben utilizar métricas estadísticas para guiar esta elección:

- **Método del Codo (Elbow Method):** Se grafica la suma de los errores cuadrados (SSE) dentro de los clústeres para diferentes valores de k. El "codo" de la curva, donde la tasa de disminución de la SSE se ralentiza bruscamente, sugiere un número óptimo de clústeres.
- **Índice de Silueta (Silhouette Index):** Esta métrica mide cuán similar es un perfil a su propio clúster en comparación con otros clústeres. Un valor cercano a 1 indica una buena agrupación. Se calcula el índice de silueta promedio para diferentes valores de k y se elige el que maximiza este índice.²⁴

- **Paso 4: Creación y Etiquetado de los TLPs:**

Una vez determinado el número óptimo de clústeres, el TLP para cada clúster se define como el centroide (el perfil promedio de todos los perfiles diarios asignados a ese clúster). A continuación, se realiza un análisis cualitativo de cada TLP para asignarle una etiqueta descriptiva, como "Residencial - Día Laborable - Pico Vespertino", "Comercial - Horario de Oficina", "Industrial - 24/7", "Fin de Semana", etc.

3.3. Aplicación de los TLPs en el Marco de Proyección

Los TLPs generados son un activo fundamental que se integra en el flujo de trabajo de la proyección de varias maneras:

- **Desagregación Histórica:** La principal aplicación es la conversión de los datos históricos de energía mensual (Emes) en una serie de carga horaria (Phora). Para un mes determinado, se asigna el TLP correspondiente a cada día (por ejemplo, TLP "Día Laborable" a los lunes-viernes, TLP "Fin de Semana" a sábados y domingos). La serie de carga horaria estimada para el mes se calcula escalando los TLPs para que la energía total coincida con la energía mensual facturada.
- **Perfiles de Carga Virtuales (VLPs):** En los casos en que no se disponga de datos horarios para una determinada empresa distribuidora o un segmento de clientes específico, se pueden utilizar los TLPs generados a partir de datos de una región o segmento similar como un "Perfil de Carga Virtual" (VLP). Esta técnica permite extender el análisis de alta frecuencia a todo el sistema, incluso con una cobertura de medición horaria incompleta.²¹

El proceso de perfilado de carga no es meramente un paso técnico de preparación de datos; es una herramienta de inteligencia de negocio y de política pública. Los clústeres resultantes segmentan el mercado de forma natural basándose en patrones de comportamiento reales. Por ejemplo, un clúster que representa hogares con un alto consumo durante el día (posiblemente por teletrabajo o presencia de amas de casa) tiene un potencial de respuesta a la demanda diferente al de un clúster de hogares que están vacíos durante el día y tienen un pico de consumo muy pronunciado por la noche. De manera similar, los clústeres industriales pueden diferenciar claramente entre operaciones de un solo turno y plantas que operan 24/7. Esta segmentación basada en datos permite a las empresas distribuidoras y al ministerio diseñar e implementar programas de eficiencia energética, tarifas dinámicas y estrategias de gestión de la demanda con una precisión y eficacia mucho mayores que las que se obtendrían utilizando categorías de clientes amplias y tradicionales como "Residencial".²³ De este modo, el ejercicio técnico de la proyección se vincula directamente con los resultados comerciales y de política, proporcionando un valor añadido que va más allá de la simple predicción.

Sección 4: Modelado Granular de la Demanda: El Motor de Proyección Bottom-Up

Esta sección detalla el núcleo del enfoque *bottom-up*, especificando los modelos y metodologías para generar proyecciones de demanda a nivel granular: para cada grupo de consumo, dentro de cada empresa distribuidora. La elección del modelo se adapta al horizonte de proyección, reconociendo que los impulsores de la demanda y la naturaleza de los datos varían significativamente entre el corto, mediano y largo plazo.

4.1. Proyección a Corto (STLF) y Mediano Plazo (MTLF) (Hasta 5 años)

Para horizontes de hasta 5 años, las proyecciones se basan en las series de tiempo de carga horaria (reales o estimadas a través de TLPs). El objetivo es capturar con precisión la dinámica de alta frecuencia, incluyendo la estacionalidad diaria, semanal y anual, así como la influencia de factores exógenos como el clima.

- **Modelos Candidatos:**
 - **SARIMAX (Seasonal Autoregressive Integrated Moving Average with Exogenous Variables):** Se recomienda como el modelo de referencia principal para esta tarea. SARIMAX es una extensión del popular modelo ARIMA que está explícitamente diseñado para manejar series de tiempo con múltiples patrones

estacionales (por ejemplo, diarios y semanales) y para incorporar el efecto de variables externas (la 'X' en SARIMAX).¹⁴ Su fortaleza radica en su robustez, su base estadística bien establecida y su alta interpretabilidad. Los coeficientes de las variables exógenas (como temperatura o un indicador de día festivo) tienen una interpretación directa, lo que es valioso para el análisis de atribución.¹⁴

- **LSTM (Long Short-Term Memory Networks):** Se presenta como una alternativa avanzada. Las LSTMs son un tipo de red neuronal recurrente particularmente eficaz para modelar dependencias a largo plazo y patrones no lineales complejos en datos secuenciales, que los modelos SARIMAX podrían no capturar completamente.⁸ Sin embargo, su implementación conlleva desafíos: requieren conjuntos de datos más grandes para el entrenamiento, un mayor poder computacional y son inherentemente modelos de "caja negra", lo que dificulta la interpretación de sus resultados.¹⁴
- **Enfoque Híbrido SARIMAX-LSTM:** Una estrategia de vanguardia consiste en combinar ambos modelos. En este enfoque, primero se ajusta un modelo SARIMAX para capturar las componentes lineales y estacionales de la serie. Luego, se entrena un modelo LSTM para predecir los residuos del modelo SARIMAX, que representan los patrones no lineales que el primer modelo no pudo capturar. La proyección final es la suma de las proyecciones de ambos modelos. Este enfoque híbrido busca combinar la interpretabilidad y la robustez de SARIMAX con la capacidad de LSTM para modelar la complejidad, a menudo resultando en una mayor precisión que cualquiera de los dos modelos por sí solo.¹⁴
- **Implementación:** Se generarán pronósticos horarios o diarios para cada serie de tiempo granular (por ejemplo, "Demanda Residencial - Empresa Eléctrica Quito S.A."). La agregación de estas proyecciones horarias a niveles mensuales y anuales formará la base de la proyección *bottom-up* para los primeros 5 años.

4.2. Proyección a Largo Plazo (LTLF) (5 a 15 años)

Para el largo plazo, la extrapolación de patrones de series de tiempo de alta frecuencia se vuelve poco fiable. Los cambios estructurales en la economía, la tecnología y la demografía se convierten en los principales impulsores de la demanda. Por lo tanto, el paradigma de modelado cambia de modelos de series de tiempo a modelos econométricos causales.¹² Estos modelos establecen relaciones explícitas y teóricamente fundamentadas entre el consumo de energía y sus determinantes económicos y demográficos fundamentales.

- **Paradigma de Modelado:** Se utilizarán modelos de regresión multivariante, estimados a partir de los datos históricos de facturación mensual (1999-presente), que ofrecen la profundidad temporal necesaria para estimar relaciones estables a largo plazo.
- **Especificación de Modelos por Sector:** Se propone una especificación de modelo log-log (doble logaritmo) para cada sector principal. Esta forma funcional es estándar en

la modelización de la demanda de energía, ya que los coeficientes de regresión pueden interpretarse directamente como elasticidades.¹¹

- Demanda Residencial: El consumo de energía por hogar está impulsado por los ingresos, los precios y las necesidades de climatización.

$$\ln(E_{\text{Res},t}) = \beta_0 + \beta_1 \ln(\text{PIB}_{\text{pc},t}) + \beta_2 \ln(\text{Poblacion}_t) + \beta_3 \ln(\text{Precio}_{\text{Elec},t}) + \beta_4 \text{HDD}_t + \beta_5 \text{CDD}_t + \beta_6 T + \epsilon_t$$

Donde $E_{\text{Res},t}$ es el consumo de energía residencial, $\text{PIB}_{\text{pc},t}$ es el PIB per cápita, $\text{Precio}_{\text{Elec},t}$ es la tarifa eléctrica real, HDD_t y CDD_t son los grados día de calefacción y refrigeración, y T es una variable de tendencia temporal que captura mejoras autónomas en la eficiencia energética.³²

- Demanda Comercial: La demanda en el sector comercial está estrechamente ligada a la actividad económica del sector de servicios.

$$\ln(E_{\text{Com},t}) = \gamma_0 + \gamma_1 \ln(\text{PIB}_{\text{Com},t}) + \gamma_2 \ln(\text{Empleo}_{\text{Com},t}) + \gamma_3 \ln(\text{Precio}_{\text{Elec},t}) + \gamma_4 \text{HDD}_t + \gamma_5 \text{CDD}_t + \epsilon_t$$

Donde $\text{PIB}_{\text{Com},t}$ es el PIB del sector comercial/servicios y $\text{Empleo}_{\text{Com},t}$ es el empleo en dicho sector.³³

- Demanda Industrial: El consumo industrial depende de la producción industrial, el precio de la electricidad y el precio de los combustibles alternativos (sustitución de energéticos).

$$\ln(E_{\text{Ind},t}) = \delta_0 + \delta_1 \ln(\text{IPI}_t) + \delta_2 \ln(\text{Precio}_{\text{Elec},t}) + \delta_3 \ln(\text{Precio}_{\text{Alt},t}) + \delta_4 T + \epsilon_t$$

Donde IPI_t es el Índice de Producción Industrial y $\text{Precio}_{\text{Alt},t}$ es el precio de combustibles alternativos como el diésel o el gas natural.³¹

- **Estimación de Parámetros:** Estos modelos se estimarán utilizando técnicas de regresión de series de tiempo. Dado que las variables económicas y de consumo de energía a menudo no son estacionarias, es crucial utilizar técnicas de cointegración, como el Modelo de Corrección de Errores (ECM), para evitar regresiones espurias y estimar correctamente tanto las relaciones de equilibrio a largo plazo (los coeficientes β, γ, δ) como la dinámica de ajuste a corto plazo.³¹

Para proporcionar una guía clara sobre la aplicación de estos modelos, se presenta la siguiente matriz de selección.

Tabla 2: Matriz de Selección de Modelos para la Proyección Bottom-Up			
Sector de	Corto Plazo (0-2	Mediano Plazo	Largo Plazo (5-15

Consumo / Nivel de Agregación	años)	(2-5 años)	años)
Residencial (por distribuidora)	Primario: SARIMAX Avanzado: Híbrido SARIMAX-LSTM	Primario: SARIMAX Avanzado: Agregación de proyecciones horarias	Primario: Modelo Econométrico Avanzado: Modelo de uso final (end-use)
Comercial (por distribuidora)	Primario: SARIMAX Avanzado: Híbrido SARIMAX-LSTM	Primario: SARIMAX Avanzado: Agregación de proyecciones horarias	Primario: Modelo Econométrico Avanzado: Modelo de uso final (end-use)
Industrial (por distribuidora)	Primario: SARIMAX Avanzado: LSTM	Primario: SARIMAX Avanzado: Agregación de proyecciones horarias	Primario: Modelo Econométrico Avanzado: Modelo de intensidad energética
Alumbrado Público y Otros	Primario: Modelo de Tendencia/Regresión simple	Primario: Modelo de Tendencia/Regresión simple	Primario: Modelo de Tendencia/Regresión simple
Justificación	Modelos de series de tiempo para capturar la dinámica de alta frecuencia y la estacionalidad fuerte. La interpretabilidad de SARIMAX es clave para el análisis operativo.	Transición de modelos de series de tiempo a modelos causales. La agregación de proyecciones de mayor frecuencia sigue siendo válida.	Los modelos econométricos son esenciales para vincular la demanda a los impulsores fundamentales del crecimiento económico y demográfico, permitiendo un análisis de escenarios robusto.

Esta matriz actúa como una guía de mejores prácticas, codificando los hallazgos de la literatura en una herramienta de decisión práctica. Asegura que se utilice la herramienta de modelado adecuada para cada tarea específica, evitando el error común de aplicar modelos de corto plazo a problemas de largo plazo y viceversa, lo que aumenta la robustez y la credibilidad de todo el sistema de proyección.

Sección 5: Escenarios Macroeconómicos e Impulsados por Políticas: Los Techos Top-Down

5.1. El Rol del Análisis de Escenarios en la Planificación a Largo Plazo

La proyección a largo plazo en el sector energético no es un ejercicio de predicción para encontrar un único valor "correcto" para el futuro. Dada la profunda incertidumbre que rodea el desarrollo económico, el cambio tecnológico y las decisiones políticas, el objetivo es explorar un rango de futuros plausibles. El análisis de escenarios es la metodología estándar a nivel internacional para gestionar esta incertidumbre.³⁶ Organizaciones como la Agencia Internacional de Energía (AIE) y el Organismo Internacional de Energía Atómica (OIEA) no producen un único pronóstico, sino un conjunto de escenarios que ilustran cómo podría evolucionar el sistema energético bajo diferentes conjuntos de supuestos.³⁸

Este enfoque permite a los planificadores y responsables de políticas evaluar la robustez de las decisiones de inversión y las estrategias frente a diversas trayectorias futuras. Al analizar los requisitos de infraestructura y los costos bajo un escenario de alta electrificación versus uno de alta eficiencia, por ejemplo, se pueden identificar estrategias de inversión "sin arrepentimiento" (*no-regret*) y desarrollar planes de contingencia. En el contexto de esta metodología, los escenarios *top-down* definen los "techos" o las metas agregadas con las que las proyecciones *bottom-up* deben ser reconciliadas, asegurando que la planificación detallada esté anclada en una visión estratégica coherente a nivel nacional.

5.2. Desarrollo de Escenarios para Ecuador

Se propone la creación de un conjunto de 3 a 4 escenarios cuantitativos distintos para la demanda total de energía y potencia máxima de Ecuador hasta el horizonte de 15 años (aproximadamente 2040). Estos escenarios deben ser internamente consistentes, plausibles y lo suficientemente diferentes entre sí para abarcar un rango significativo de incertidumbre.

- **Escenario 1: Políticas Declaradas (Stated Policies) / Caso Base:** Este escenario representa la trayectoria futura si se mantienen las tendencias actuales y se implementan las políticas y planes ya anunciados oficialmente. Para Ecuador, este escenario debe estar directamente anclado en las proyecciones del **Plan Maestro de Electricidad 2023-2032**. Dicho plan proyecta que la demanda de electricidad crecerá un 60%, pasando de 31,483 GWh en 2023 a **50,544 GWh en 2032**.⁶ Las proyecciones más allá de 2032 se extrapolarían manteniendo las tasas de crecimiento implícitas en el plan. Este escenario sirve como el punto de referencia contra el cual se comparan los demás.
- **Escenario 2: Electrificación Acelerada:** Este es un escenario de alta demanda que asume una adopción más rápida de tecnologías eléctricas clave, superando las metas del Plan Maestro. Los impulsores clave incluirían:
 - Una penetración más agresiva de vehículos eléctricos en el parque automotor.
 - Una transición más rápida de procesos industriales (por ejemplo, en el sector camaronero) y de cocción residencial del gas/diésel a la electricidad.
 - El desarrollo de nuevos grandes consumidores industriales (minería, centros de datos) a un ritmo mayor del previsto.
- **Escenario 3: Alta Eficiencia Energética:** Este es un escenario de baja demanda que explora el impacto de políticas de eficiencia energética y gestión de la demanda más ambiciosas. Los supuestos clave serían:
 - Implementación de estándares de eficiencia más estrictos para edificios, electrodomésticos y equipos industriales.
 - Adopción a gran escala de programas de respuesta a la demanda que reduzcan la demanda máxima.
 - Un cambio estructural en la economía hacia sectores de servicios menos intensivos en energía.

5.3. Cuantificación de los Impulsores de los Escenarios

Cada escenario debe ser definido por un conjunto específico y cuantitativo de supuestos para sus impulsores clave. Estas cifras deben provenir de fuentes oficiales nacionales e internacionales para garantizar su credibilidad.

- **Impulsores Macroeconómicos:**
 - **Crecimiento del PIB:** Se deben utilizar las proyecciones oficiales del Banco Central del Ecuador y compararlas con las del Fondo Monetario Internacional (FMI) para establecer un rango de crecimiento para cada escenario.⁴¹ Por ejemplo, el escenario

- de alta demanda podría usar la proyección de crecimiento del PIB más optimista.
- **Crecimiento de la Población:** Utilizar las proyecciones demográficas del Instituto Nacional de Estadística y Censos (INEC).
 - **Impulsores de Política y Tecnología:**
 - **Metas de Electrificación:** Cuantificar el número de vehículos eléctricos, el porcentaje de hogares con cocción eléctrica, etc., para cada año del horizonte de proyección en cada escenario.
 - **Tasas de Mejora de la Eficiencia:** Definir una tasa anual de mejora de la intensidad energética (consumo de energía por unidad de PIB) para cada escenario.
 - **Nuevas Cargas Industriales:** Incorporar explícitamente la demanda esperada de proyectos específicos, como los proyectos mineros mencionados en el análisis del Plan Maestro.⁶

La siguiente tabla ejemplifica cómo se pueden estructurar estos supuestos de manera transparente.

Tabla 3: Supuestos Clave para los Escenarios Top-Down (2025-2040)			
Impulsor Clave	Escenario 1: Políticas Declaradas (Caso Base)	Escenario 2: Electrificación Acelerada	Escenario 3: Alta Eficiencia Energética
Crecimiento Promedio Anual del PIB (2025-2032)	2.5% (Basado en BCE/PME) ⁴²	3.5% (Crecimiento alto)	1.8% (Crecimiento bajo)
Parque de Vehículos Eléctricos (millones, 2035)	0.8	1.5	0.6
Electrificación de la Cocción	40%	60%	40%

Residencial (% hogares, 2035)			
Demanda de Nuevos Proyectos Mineros (GWh/año, 2030)	2,500 ⁶	3,500	2,000
Mejora Anual de la Intensidad Energética	-1.0%	-0.8%	-2.0%
Demanda Nacional Total de Energía (GWh, 2032)	50,544 ⁶	58,000	45,000

Esta tabla es fundamental porque hace que el proceso de construcción de escenarios sea transparente y auditable. Permite a los responsables de la toma de decisiones y a las partes interesadas comprender claramente qué "palancas" definen cada futuro posible. Facilita el análisis de sensibilidad y fomenta un debate estratégico más sofisticado e informado, pasando de la pregunta "¿Cuál es el pronóstico?" a "¿Estamos preparados para este rango de futuros?".

Sección 6: El Motor de Convergencia: Un Marco de Reconciliación Iterativo

6.1. El Problema de la Incoherencia en la Proyección Jerárquica

Un sistema de proyección que genera pronósticos a múltiples niveles de agregación (nacional, por empresa distribuidora, por sector de consumo) se enfrenta a un desafío fundamental: la coherencia. Cuando los pronósticos para cada nivel se generan de forma independiente, es prácticamente seguro que no serán aditivos. Por ejemplo, la suma de las proyecciones para todas las empresas distribuidoras no coincidirá con la proyección

generada para el total nacional, y la suma de las proyecciones para todos los sectores de consumo no coincidirá con ninguna de las dos. Esta propiedad se conoce como **incoherencia** de los pronósticos.¹

Las series de tiempo que se agregan de esta manera se denominan series de tiempo jerárquicas o agrupadas.² Mantener la coherencia es deseable no solo por una cuestión de consistencia contable, sino porque se ha demostrado que los métodos de reconciliación que imponen esta coherencia también pueden mejorar la precisión de los pronósticos en todos los niveles de la jerarquía.⁴⁴

Los enfoques tradicionales para lograr la coherencia son simples pero fundamentalmente defectuosos:

- **Enfoque Top-Down:** Se genera un pronóstico solo para el nivel más alto (total nacional) y luego se desagrega a los niveles inferiores utilizando proporciones históricas. Este método garantiza la coherencia, pero pierde la información valiosa contenida en las series de tiempo de los niveles inferiores y puede producir pronósticos de baja calidad en los niveles granulares.¹
- **Enfoque Bottom-Up:** Se generan pronósticos solo para el nivel más bajo (por ejemplo, sector/distribuidora) y se suman para obtener los pronósticos de los niveles superiores. Aunque este método es estadísticamente insesgado, a menudo produce pronósticos inexactos en los niveles superiores, ya que los errores de pronóstico de los niveles inferiores se acumulan y se magnifican en el proceso de suma.¹

Para superar estas limitaciones, se requiere un enfoque más sofisticado que utilice toda la información disponible en la jerarquía.

6.2. Reconciliación Óptima con Mínima Traza (MinT)

La reconciliación óptima es un marco estadístico moderno que ajusta un conjunto inicial de pronósticos base (incoherentes) para producir un nuevo conjunto de pronósticos reconciliados que son coherentes y, lo que es más importante, tienen la mínima varianza de error de pronóstico posible.¹

El método de referencia en este campo es el de **Mínima Traza (MinT)**. En lugar de descartar algunos pronósticos y conservar otros, MinT considera todos los pronósticos base en todos los niveles de la jerarquía como información valiosa. Resuelve un problema de optimización de mínimos cuadrados generalizados que encuentra una combinación lineal de todos los pronósticos base para producir los pronósticos reconciliados. Esta combinación se elige de tal manera que la varianza total de los errores del pronóstico reconciliado (representada por

la traza de su matriz de covarianza) se minimice.¹ En esencia, MinT encuentra la "media ponderada" óptima de todos los pronósticos en la jerarquía, donde las ponderaciones se derivan de la estructura de covarianza de los errores de los pronósticos base.

6.3. El Algoritmo "Forward-Backward": Una Implementación Práctica mediante Ajuste Proporcional Iterativo (IPF)

Si bien MinT proporciona la base teórica para la reconciliación óptima, la solicitud específica del usuario de un proceso "forward-backward" análogo al flujo de carga encuentra un equivalente matemático directo y práctico en un algoritmo conocido como **Ajuste Proporcional Iterativo (IPF)**, también llamado algoritmo RAS en economía.⁴⁷ Este algoritmo está diseñado precisamente para ajustar los valores internos de una matriz para que coincidan con totales marginales (sumas de filas y columnas) preespecificados, preservando al mismo tiempo la estructura subyacente de la matriz original tanto como sea posible.⁴⁷

El mapeo de este algoritmo al problema de la proyección de la demanda es directo y elegante:

- La **matriz inicial** es la matriz de pronósticos base *bottom-up*, donde, por ejemplo, las filas representan a las empresas distribuidoras y las columnas a los grupos de consumo.
- Los **totales marginales objetivo** son los pronósticos *top-down* de los escenarios. Los totales de las columnas objetivo son los pronósticos nacionales para cada grupo de consumo, y los totales de las filas objetivo son los pronósticos totales para cada empresa distribuidora.

El algoritmo funciona de la siguiente manera, alternando entre la reconciliación a lo largo de las columnas y las filas hasta que se alcanza la convergencia:

1. **Paso 0 (Inicialización):** Se construye la matriz de pronósticos base, $F(0)$, con las proyecciones *bottom-up* para cada combinación de distribuidora (fila i) y grupo de consumo (columna j). Se definen los vectores de totales objetivo: $T_{j\text{sector}}$ (total para el sector j) y $T_{i\text{dist}}$ (total para la distribuidora i), derivados de los escenarios *top-down*.
2. **Paso 1 (Pase "Adelante" - Reconciliación por Sector):** En la primera iteración ($k=1$), se ajusta cada columna de la matriz para que su suma coincida con el total del sector correspondiente. Para cada celda (i,j) :

$$F_{ij}(k, \text{paso 1}) = F_{ij}(k-1) \times \frac{T_{j\text{sector}}}{\sum_i F_{ij}(k-1)}$$

Este paso asegura que la suma de la demanda de todas las distribuidoras para un sector dado (por ejemplo, Residencial) sea igual al objetivo nacional para ese sector.

3. **Paso 2 (Pase "Atrás" - Reconciliación por Distribuidora):** El ajuste anterior habrá alterado

las sumas de las filas. Ahora, se ajusta cada fila de la matriz resultante para que su suma coincida con el total de la distribuidora correspondiente. Para cada celda (i,j):

$$F_{ij}^{(k)} = F_{ij}^{(k, \text{paso 1})} \times \frac{T_i^{\text{dist}}}{\sum_j F_{ij}^{(k, \text{paso 1})}}$$

Este paso asegura que la suma de la demanda de todos los sectores para una distribuidora dada sea igual al objetivo total para esa distribuidora.

4. **Paso 3 (Iteración):** Se repiten los Pasos 1 y 2. Cada ciclo de ajuste de columnas y luego de filas acerca la matriz a una solución que satisface simultáneamente ambos conjuntos de restricciones marginales. Se ha demostrado que este procedimiento converge a una matriz única que cumple con los totales marginales y minimiza la divergencia de información (distancia de Kullback-Leibler) con respecto a la matriz original, lo que significa que preserva la estructura de las proporciones relativas de los pronósticos base *bottom-up*.⁴⁷
5. **Paso 4 (Verificación de Convergencia):** El bucle iterativo continúa hasta que el cambio máximo en cualquier celda de la matriz entre una iteración y la siguiente sea menor que un umbral de tolerancia predefinido, ϵ (por ejemplo, 10^{-5}).⁴⁶

El siguiente pseudo-código formaliza este procedimiento.

Tabla 4: El Algoritmo de Ajuste "Forward-Backward" (Pseudo-código)
Función Reconciliacion_IPF
Entradas:
F_base: Matriz (I x J) de pronósticos base bottom-up (I=distribuidoras, J=sectores).
T_sector: Vector (J x 1) de totales objetivo por sector (top-down).
T_dist: Vector (I x 1) de totales objetivo por distribuidora (top-down).
max_iter: Número máximo de iteraciones (ej. 100).
tolerancia: Umbral de convergencia (ej. 1e-5).
Salida:
F_reconciliada: Matriz (I x J) de pronósticos reconciliados y coherentes.

Procedimiento:
1. $F_{actual} \leftarrow F_{base}$
2. PARA iter desde 1 hasta max_iter:
3. $F_{anterior} \leftarrow F_{actual}$
4. // Pase "Adelante": Ajuste por columnas (Sectores)
5. $Suma_columnas \leftarrow$ Suma de cada columna de F_{actual}
6. $Factor_escala_col \leftarrow T_{sector} / Suma_columnas$
7. $F_{actual} \leftarrow F_{actual} * Factor_escala_col$ (multiplicación por elemento, broadcasting)
8. // Pase "Atrás": Ajuste por filas (Distribuidoras)
9. $Suma_filas \leftarrow$ Suma de cada fila de F_{actual}
10. $Factor_escala_fila \leftarrow T_{dist} / Suma_filas$
11. $F_{actual} \leftarrow F_{actual} * Factor_escala_fila$ (multiplicación por elemento, broadcasting)
12. // Verificación de Convergencia
13. $cambio_max \leftarrow$ Máximo valor absoluto de $(F_{actual} - F_{anterior})$
14. SI $cambio_max < tolerancia$:
15. RETORNAR F_{actual}
16. FIN PARA
17. ADVERTENCIA: "Convergencia no alcanzada en max_iter iteraciones."
18. RETORNAR F_{actual}

Este algoritmo proporciona un método robusto, eficiente y teóricamente sólido para implementar el concepto de "avance-retroceso", traduciendo la teoría matemática de la reconciliación en un conjunto de pasos computacionales claros y directamente implementables.

Sección 7: Proyección de la Demanda y Pérdidas Técnicas a través de la Cadena de Valor del Sistema Eléctrico

7.1. De la Demanda del Usuario Final a la Carga del Sistema

Las proyecciones de demanda reconciliadas obtenidas en la sección anterior representan la energía que se espera facturar a los consumidores finales. Sin embargo, para la planificación de la generación y la transmisión, es necesario determinar la cantidad total de energía que debe ser inyectada en el sistema para satisfacer esa demanda final. Esta traducción implica agregar sistemáticamente las pérdidas técnicas que ocurren en cada etapa de la cadena de valor del sistema eléctrico: distribución, subtransmisión y transmisión.⁵⁰

La demanda en un punto aguas arriba del sistema siempre será mayor que la suma de las demandas aguas abajo debido a estas pérdidas. Por lo tanto, el proceso consiste en:

1. Comenzar con la demanda de energía reconciliada a nivel de usuario final (facturada).
2. Estimar y agregar las pérdidas en las redes de baja y media tensión para determinar la demanda en las subestaciones de distribución.
3. Estimar y agregar las pérdidas en las redes de subtransmisión para determinar la demanda en los puntos de entrega de la red de transmisión.
4. Estimar y agregar las pérdidas en la red de transmisión para determinar la demanda total en las barras de las centrales de generación (generación bruta requerida).

Un pronóstico preciso de estas pérdidas es, por lo tanto, un componente crítico del sistema de proyección general.

7.2. Modelado y Proyección de Pérdidas Técnicas (Enfoque Macro)

Las pérdidas técnicas son inherentes a la operación de un sistema de potencia y se deben a la disipación de energía en forma de calor en los componentes de la red (conductores, transformadores, etc.).⁵⁰ Se pueden clasificar en dos categorías principales, cada una de las cuales requiere un enfoque de modelado diferente.⁵⁰

- **Pérdidas Fijas (o sin Carga):**

- **Descripción:** Estas pérdidas no dependen de la cantidad de corriente que fluye por la red. Ocurren siempre que los equipos están energizados. Las principales fuentes son las pérdidas en el núcleo de los transformadores (pérdidas por histéresis y corrientes de Foucault) y las pérdidas por efecto corona en las líneas de alta tensión.⁵⁰ Constituyen aproximadamente entre 1/4 y 1/3 del total de las pérdidas técnicas.
- **Modelado y Proyección:** Las pérdidas fijas pueden estimarse como un porcentaje de la capacidad del equipo instalado (por ejemplo, el número y la capacidad en kVA de los transformadores de distribución). Para la proyección, se puede suponer que estas pérdidas crecerán en proporción a la expansión planificada de la red. Por ejemplo, si se proyecta un aumento del 10% en la capacidad de transformación instalada para satisfacer el crecimiento de la demanda, se puede proyectar un aumento similar en las pérdidas fijas.

- **Pérdidas Variables (o con Carga):**

- **Descripción:** Estas pérdidas son la componente dominante (2/3 a 3/4 del total) y están directamente relacionadas con la carga. Se deben principalmente a las pérdidas por efecto Joule (calentamiento óhmico) en los conductores, que son proporcionales al cuadrado de la corriente ($P_{pérdidas} = I^2 R$). Esto significa que un aumento del 10% en la corriente resulta en un aumento del 21% en las pérdidas ($1.12^2 = 1.2544$).⁵⁰ Las pérdidas variables dependen críticamente de factores como la longitud y el calibre de los conductores, el factor de potencia del sistema y el equilibrio de carga entre las fases.
- **Modelado y Proyección:** Proyectar las pérdidas de energía variables es más complejo que proyectar las pérdidas de potencia en el momento de la demanda máxima. La clave es la relación entre el **Factor de Carga** y el **Factor de Pérdidas**.
 - El **Factor de Carga (FC)** se define como la carga promedio durante un período dividida por la carga máxima en ese período: $FC = P_{prom} / P_{max}$. Un FC bajo indica una carga "puntiaguda", mientras que un FC alto indica una carga más constante.⁵⁰
 - El **Factor de Pérdidas (FP)** se define de manera análoga: pérdidas promedio divididas por las pérdidas en el momento de la carga máxima.
 - Dado que las pérdidas son proporcionales al cuadrado de la carga, la relación entre estos dos factores no es lineal. Se pueden utilizar fórmulas empíricas,

validadas en la industria, para estimar el Factor de Pérdidas a partir del Factor de Carga. Una fórmula comúnmente utilizada es:

$$FP \approx a \cdot (FC) + (1-a) \cdot (FC)^2$$

Donde el coeficiente a suele estar en el rango de 0.15 a 0.3. Una aproximación simplificada es $FP \approx 0.3 \cdot (FC) + 0.7 \cdot (FC)^2$.⁵¹

- **Proceso de Proyección:**

1. Utilizando los perfiles de carga horarios (TLPs) generados en la Sección 3 para cada segmento del sistema, se calcula el Factor de Carga proyectado para cada año.
2. Se utiliza la fórmula empírica para estimar el Factor de Pérdidas proyectado a partir del Factor de Carga proyectado.
3. Se calcula la pérdida de potencia máxima ($P_{pérdidas,max}$) en el momento de la demanda máxima proyectada, utilizando un modelo de flujo de carga simplificado o porcentajes históricos.
4. Finalmente, la energía total perdida durante el año ($E_{pérdidas}$) se calcula como:
 $E_{pérdidas} = P_{pérdidas,max} \times FP \times 8760$ horas.

Este enfoque detallado permite una proyección dinámica de las pérdidas que tiene en cuenta no solo el crecimiento de la demanda máxima, sino también los cambios en la *forma* de la curva de carga.

7.3. Modelado de Alta Precisión de Pérdidas mediante Simulación de Flujo de Potencia

Para obtener la máxima precisión y granularidad, especialmente para la planificación de la red de distribución, el método preferido es la simulación detallada de la red mediante un análisis de flujo de potencia (o flujo de carga). Este enfoque de "ingeniería" modela el sistema eléctrico basándose en sus componentes físicos y las leyes fundamentales de los circuitos, proporcionando una estimación de pérdidas por elemento.

El proceso de simulación se desarrolla en los siguientes pasos:

1. **Construcción del Modelo de Red:** Se crea una réplica digital de la red de distribución en un software especializado, como el simulador de sistemas de distribución de código abierto **OpenDSS**. Este modelo debe incluir información detallada sobre la topología y los parámetros eléctricos de cada componente:
 - **Topología:** La conectividad exacta de subestaciones, alimentadores, transformadores, líneas de media y baja tensión, y puntos de carga.

- **Parámetros de Líneas:** Resistencia, reactancia, longitud y tipo de conductor para cada segmento de la red.
 - **Parámetros de Transformadores:** Capacidad (kVA), niveles de voltaje, impedancia, y pérdidas con y sin carga (pérdidas de cobre y de núcleo).
2. **Asignación de Cargas Proyectadas:** Las proyecciones de demanda horaria reconciliadas (de la Sección 6) se asignan a los nodos de carga correspondientes en el modelo de red. Para una mayor precisión, los datos de medidores inteligentes (AMI), si están disponibles, se pueden agregar a nivel de transformador de distribución o alimentador.
 3. **Ejecución de Simulación de Flujo de Potencia:** Para cada intervalo de tiempo del horizonte de proyección (por ejemplo, cada hora), el software de simulación resuelve las ecuaciones de flujo de potencia de la red. Este cálculo determina el voltaje en cada nodo y, crucialmente, el flujo de corriente (I) a través de cada elemento de la red (líneas, transformadores).
 4. **Cálculo de Pérdidas por Elemento:** Con la corriente calculada para cada elemento y su resistencia (R) conocida, las pérdidas de potencia variables (pérdidas por efecto Joule) para ese elemento en ese instante de tiempo se calculan directamente con la fórmula $P_{\text{pérdidas}} = I^2 R$. Las pérdidas fijas (sin carga) de los transformadores se suman a este valor.
 5. **Agregación y Proyección de Energía Perdida:** El proceso se repite para cada hora del período de proyección (por ejemplo, las 8760 horas de un año). La energía total perdida ($E_{\text{pérdidas}}$) es la suma (o la integral) de las pérdidas de potencia calculadas en cada intervalo horario.

Este enfoque, aunque computacionalmente más intensivo y exigente en datos que el método macro, ofrece ventajas significativas. Permite identificar con precisión los puntos críticos de la red (alimentadores o transformadores con mayores pérdidas) y evaluar el impacto de posibles inversiones, como la repotenciación de conductores o el reequilibrio de fases, en la reducción de pérdidas.

El modelado de pérdidas no es simplemente un ejercicio contable para llegar a la generación bruta. Es una herramienta de diagnóstico poderosa para la planificación de la red. Las pérdidas variables crecen con el cuadrado de la corriente. Si la demanda aumenta, pero la inversión en la capacidad de los conductores (por ejemplo, repotenciación de líneas o instalación de nuevos circuitos) se retrasa, la densidad de corriente en la red existente aumentará. Esto provocará que las pérdidas variables crezcan a un ritmo más rápido que la propia demanda, lo que resultará en un aumento del porcentaje de pérdidas totales. Por lo tanto, el pronóstico de pérdidas, cuando se compara con el pronóstico de demanda, se convierte en un indicador clave de la eficiencia y la salud de la red. Puede utilizarse para identificar de forma proactiva las áreas del sistema que se están convirtiendo en cuellos de botella y que requieren inversiones de capital, vinculando directamente el pronóstico de la demanda con la planificación de la transmisión y la distribución. Además, cuantifica el beneficio económico de las intervenciones para mejorar la eficiencia, como la mejora del

factor de potencia o el equilibrio de cargas.⁵⁰

Sección 8: Hoja de Ruta de Implementación, Validación y Gobernanza del Modelo

8.1. Plan de Implementación por Fases

El desarrollo e implementación de un sistema de proyección de esta magnitud y complejidad debe abordarse de manera estructurada y por fases para garantizar el éxito, gestionar los recursos y obtener valor en cada etapa. Se propone el siguiente plan de implementación:

- **Fase 1: Arquitectura de Datos y Preprocesamiento (Meses 1-4):**
 1. **Inventario y Consolidación:** Realizar el inventario completo de datos, diseñar el esquema de la base de datos centralizada y ejecutar los scripts para la ingesta y consolidación de todos los datos históricos.
 2. **Pipeline de Limpieza:** Desarrollar y aplicar sistemáticamente los algoritmos de limpieza de datos, incluyendo la detección de valores atípicos y la imputación de valores faltantes.
 3. **Ingeniería de Características:** Recopilar y alinear temporalmente todas las variables exógenas (meteorológicas, de calendario, macroeconómicas) y crear las características derivadas (HDD, CDD, etc.).
 - **Entregable:** Una base de datos limpia, consolidada y enriquecida, lista para el modelado.
- **Fase 2: Perfilado de Carga y Desarrollo de Modelos Base Bottom-Up (Meses 5-8):**
 1. **Generación de TLPs:** Aplicar los algoritmos de clustering a los datos horarios para generar el catálogo de Perfiles de Carga Típicos para cada sector.
 2. **Desagregación Histórica:** Utilizar los TLPs para convertir toda la serie histórica de facturación mensual en series de carga horaria estimada.
 3. **Modelos de Referencia:** Desarrollar y calibrar los modelos de proyección base *bottom-up* (por ejemplo, SARIMAX para el corto/mediano plazo y econométricos para el largo plazo) para cada serie granular.
 - **Entregable:** Un conjunto completo de proyecciones base *bottom-up* (incoherentes) y un catálogo de TLPs.
- **Fase 3: Desarrollo de Escenarios Top-Down y Motor de Reconciliación (Meses 9-11):**
 1. **Definición de Escenarios:** Trabajar con las partes interesadas (ministerio, regulador, planificadores) para definir y cuantificar los supuestos de los escenarios *top-down*

(Políticas Declaradas, Electrificación Acelerada, etc.).

2. **Proyecciones Top-Down:** Generar las proyecciones agregadas para cada escenario.
3. **Implementación del Motor de Reconciliación:** Codificar y probar el algoritmo de reconciliación iterativo (IPF) descrito en la Sección 6.
 - **Entregable:** Un conjunto de proyecciones de control *top-down* y el software funcional del motor de reconciliación.
- **Fase 4: Integración, Modelado de Pérdidas y Despliegue (Meses 12-14):**
 1. **Integración y Ejecución:** Integrar todas las componentes, ejecutar el proceso completo para generar el primer conjunto de proyecciones reconciliadas.
 2. **Modelado de Pérdidas:** Desarrollar y aplicar el modelo de pérdidas técnicas para traducir la demanda final en demanda del sistema.
 3. **Despliegue y Visualización:** Desplegar el sistema en un entorno de producción y desarrollar herramientas de visualización (dashboards) para que los usuarios finales puedan explorar los resultados.
 - **Entregable:** El primer "vintage" oficial de proyecciones de demanda coherentes y una plataforma para su diseminación.

8.2. Validación del Modelo y Métricas de Rendimiento

La credibilidad del sistema de proyección depende de una validación rigurosa y transparente de su precisión.

- **Backtesting (Validación Retrospectiva):** El enfoque principal para la validación es el *backtesting*. El procedimiento consiste en utilizar un conjunto de datos de entrenamiento "congelado" en un punto del pasado (por ejemplo, todos los datos hasta el final de 2020) para generar proyecciones para un período histórico posterior (por ejemplo, 2021-2023), que se reserva como conjunto de prueba. Luego, las proyecciones se comparan con los valores reales observados durante ese período de prueba. Este proceso simula de manera realista cómo se habría comportado el modelo en el pasado y proporciona una evaluación objetiva de su precisión predictiva fuera de la muestra.
- **Métricas de Rendimiento:** La precisión del pronóstico debe evaluarse en todos los niveles de la jerarquía utilizando un conjunto estándar de métricas de error:
 - **Error Porcentual Absoluto Medio (MAPE):** $MAPE = \frac{1}{n} \sum_{t=1}^n \left| \frac{A_t - F_t}{A_t} \right|$. Es fácil de interpretar como el error porcentual promedio, pero puede ser problemático si los valores reales (A_t) son cercanos a cero.²⁸
 - **Raíz del Error Cuadrático Medio (RMSE):** $RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (A_t - F_t)^2}$. Penaliza más los errores grandes y está en las mismas unidades que la variable pronosticada, pero es menos intuitivo en términos de escala.⁸
 - **Error Absoluto Escalonado Medio (MASE):** Compara el error del modelo con el

error de un pronóstico ingenuo (por ejemplo, el valor del período anterior). Un MASE < 1 indica que el modelo es mejor que el pronóstico ingenuo. Es independiente de la escala y, por lo tanto, útil para comparar la precisión entre series con diferentes magnitudes.

8.3. Gobernanza y Mantenimiento del Modelo

Un sistema de proyección no es un proyecto de una sola vez, sino un activo analítico que debe ser mantenido y gobernado activamente para que siga siendo relevante y fiable.

- **Cadencia de Actualización:** Se debe establecer un ciclo de vida formal para el proceso de proyección. Se recomienda un ciclo anual completo, que coincida con la publicación de nuevos datos macroeconómicos y la revisión de los planes del sector. Este ciclo incluiría:
 1. Actualización de todos los datos históricos.
 2. Revisión y, si es necesario, recalibración de los parámetros del modelo.
 3. Revisión de los supuestos de los escenarios *top-down* con las partes interesadas.
 4. Ejecución del sistema completo para generar un nuevo "vintage" oficial de proyecciones.
- **Control de Versiones:** Es imperativo implementar un sistema de control de versiones (como Git) para todos los componentes del sistema: el código fuente de los modelos, los conjuntos de datos de entrada y los resultados de las proyecciones. Esto garantiza la total transparencia, reproducibilidad y auditabilidad del proceso. Cualquier persona debería poder, en el futuro, replicar exactamente cómo se generó un pronóstico específico.
- **Revisión por Parte de los Interesados:** El proceso de proyección no debe operar en un vacío. Se debe establecer un comité de gobernanza o un grupo de trabajo que incluya representantes de las principales partes interesadas (Ministerio de Energía, CENACE, empresas de distribución, grandes consumidores, academia). Este grupo se reuniría en puntos clave del ciclo anual para revisar y validar los supuestos de entrada (especialmente los de los escenarios) y para analizar y discutir los resultados de las proyecciones antes de su publicación oficial. Este proceso de revisión colaborativa aumenta la aceptación y la credibilidad de los pronósticos y asegura que sigan siendo relevantes para las necesidades de todos los actores del sector.

Conclusiones

La metodología detallada en este informe presenta un marco integral y robusto para la proyección de la demanda de potencia y energía eléctrica en Ecuador, diseñado para abordar las complejidades de un sistema energético moderno y para satisfacer las necesidades de planificación a corto, mediano y largo plazo. Al adoptar una arquitectura híbrida que combina la precisión granular de los modelos *bottom-up* con la coherencia estratégica de los escenarios *top-down*, el sistema propuesto supera las limitaciones de los enfoques monolíticos tradicionales.

Las conclusiones y recomendaciones clave son las siguientes:

1. **La Reconciliación es Clave para la Coherencia y la Precisión:** La adopción de un marco de reconciliación jerárquica, implementado a través del algoritmo iterativo "forward-backward" (IPF), es el pilar central de la metodología. Este enfoque no solo garantiza la consistencia matemática de las proyecciones en todos los niveles de agregación, sino que también mejora la precisión general al aprovechar toda la información contenida en la jerarquía. Más allá de su función técnica, el proceso de reconciliación sirve como una herramienta estratégica para cuantificar la brecha entre las tendencias de consumo actuales y los objetivos de política energética a largo plazo.
2. **El Modelado Adaptativo es Esencial:** No existe un único modelo de proyección que sea óptimo para todos los propósitos. La metodología reconoce esta realidad al prescribir un enfoque modular: modelos de series de tiempo como SARIMAX y LSTM para la dinámica de corto y mediano plazo, y modelos econométricos causales para las proyecciones de largo plazo. Esta selección adaptativa asegura que se utilice la herramienta más apropiada para cada tarea, equilibrando la precisión, la interpretabilidad y la relevancia política.
3. **La Calidad de los Datos es el Fundamento:** El éxito de todo el sistema depende de un pipeline de preprocesamiento de datos riguroso y sistemático. La limpieza de datos, la imputación de valores faltantes, el tratamiento de valores atípicos y la ingeniería de características no son pasos preliminares, sino componentes integrales del proceso de modelado que deben ser ejecutados con el máximo rigor para garantizar la fiabilidad de los resultados.
4. **Del Pronóstico a la Planificación Accionable:** La metodología va más allá de la simple generación de números. Al integrar el perfilado de carga y el modelado detallado de pérdidas técnicas, el sistema produce resultados que informan directamente la planificación operativa y de infraestructura. Los perfiles de carga permiten una segmentación de clientes basada en el comportamiento para programas de gestión de la demanda, mientras que el pronóstico de pérdidas actúa como un diagnóstico de la salud de la red, identificando cuellos de botella y justificando inversiones.

Recomendación Final:

Se recomienda la adopción e implementación por fases de esta metodología como el sistema oficial de proyección de la demanda para el sector eléctrico ecuatoriano. Su implementación no solo proporcionará pronósticos más precisos y coherentes, sino que también establecerá

una plataforma analítica avanzada que puede apoyar una toma de decisiones más informada y estratégica en todas las áreas de la planificación energética, desde la operación diaria del sistema hasta la definición de la política energética nacional para las próximas décadas. La inversión en el desarrollo de este sistema es una inversión en la resiliencia, eficiencia y sostenibilidad del futuro eléctrico de Ecuador.

Obras citadas

1. Demystifying Hierarchical Forecasting | by Mark Goh | Medium, fecha de acceso: septiembre 8, 2025, <https://medium.com/@gmw172/demystifying-hierarchical-forecasting-6c0dc585ced8>
2. Cross-Temporal Hierarchical Forecast Reconciliation of Natural Gas Demand - MDPI, fecha de acceso: septiembre 8, 2025, <https://www.mdpi.com/1996-1073/17/13/3077>
3. Hybrid Bottom-up/Top-down Energy and Economy Outlooks: A Review of IMACLIM-S Experiments - Frontiers, fecha de acceso: septiembre 8, 2025, <https://www.frontiersin.org/journals/environmental-science/articles/10.3389/fenvs.2015.00074/full>
4. Ecuador proyecta USD 10.446,5 millones para garantizar el suministro eléctrico - RTU, fecha de acceso: septiembre 8, 2025, <https://canalrtu.tv/2024/08/27/plan-maestro-de-electricidad-2023-2032/>
5. The Master Plan for Electricity 2023 – 2032 - Climate Change Laws of the World, fecha de acceso: septiembre 8, 2025, https://climate-laws.org/document/the-master-plan-for-electricity-2023-2032_46aa
6. Superar los cortes de luz en Ecuador requerirá de una inversión de ..., fecha de acceso: septiembre 8, 2025, <https://www.primicias.ec/economia/cortes-luz-crisis-electrica-plan-nuevas-centrales-inversion-77286/>
7. (PDF) Hybrid Bottom-Up/Top-Down Modeling of Prices in Deregulated Wholesale Power Markets - ResearchGate, fecha de acceso: septiembre 8, 2025, https://www.researchgate.net/publication/225946668_Hybrid_Bottom-UpTop-Down_Modeling_of_Prices_in_Deregulated_Wholesale_Power_Markets
8. Accurate prediction of electricity consumption using a hybrid CNN-LSTM model based on multivariable data | PLOS One - Research journals, fecha de acceso: septiembre 8, 2025, <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0278071>
9. Seasonal Forecasting Techniques for Time Series Analysis - Train in Data's Blog, fecha de acceso: septiembre 8, 2025, <https://www.blog.trainindata.com/seasonal-time-series-forecasting/>
10. Review of Methods and Models for Forecasting Electricity Consumption - MDPI, fecha de acceso: septiembre 8, 2025, <https://www.mdpi.com/1996-1073/18/15/4032>
11. Long Term Power Demand Forecasting using Regression Model - SAARC Energy

- Centre, fecha de acceso: septiembre 8, 2025,
<https://www.saarcenergy.org/wp-content/uploads/2018/05/Long-Term-Power-Demand-Forecasting-using-Regression-Model-by-Mr.-Tauseef.pdf>
12. Models for Long-Term Energy Forecasting - ResearchGate, fecha de acceso: septiembre 8, 2025,
https://www.researchgate.net/publication/4055566_Models_for_Long-Term_Energy_Forecasting
 13. A REVIEW OF LOAD FORECASTING METHODOLOGIES - Center for Agricultural and Rural Development, fecha de acceso: septiembre 8, 2025,
<https://www.card.iastate.edu/products/publications/pdf/84wp5.pdf>
 14. Hybrid Forecasting for Sustainable Electricity Demand in The ... - MDPI, fecha de acceso: septiembre 8, 2025, <https://www.mdpi.com/2071-1050/17/16/7192>
 15. (PDF) A Review on Data Preprocessing Techniques Toward Efficient and Reliable Knowledge Discovery From Building Operational Data - ResearchGate, fecha de acceso: septiembre 8, 2025,
https://www.researchgate.net/publication/350466129_A_Review_on_Data_Preprocessing_Techniques_Toward_Efficient_and_Reliable_Knowledge_Discovery_From_Building_Operational_Data
 16. A Survey of Preprocessing Methods Used for Analysis of Big Data Originated From Smart Grids | OPUS at UTS, fecha de acceso: septiembre 8, 2025,
https://opus.lib.uts.edu.au/bitstream/10453/170923/2/A_Survey_of_Preprocessing_Methods_Used_for_Analysis_of_Big_Data_Originated_From_Smart_Grids.pdf
 17. Load Forecasting Models in Smart Grid Using Smart Meter Information: A Review - MDPI, fecha de acceso: septiembre 8, 2025,
<https://www.mdpi.com/1996-1073/16/3/1404>
 18. (PDF) Data Preprocessing in Electrical Energy Consumption Profile Clustering Studies, fecha de acceso: septiembre 8, 2025,
https://www.researchgate.net/publication/370105694_Data_Preprocessing_in_Electrical_Energy_Consumption_Profile_Clustering_Studies
 19. Time Series Analysis: Steps, Types, and Examples - MATLAB & Simulink - MathWorks, fecha de acceso: septiembre 8, 2025,
<https://www.mathworks.com/discovery/time-series-analysis.html>
 20. Before the Forecast: Exploring and Preparing Time Series Data | by Charu Agarwal - AI Mind, fecha de acceso: septiembre 8, 2025,
<https://pub.aimind.so/before-the-forecast-exploring-and-preparing-time-series-data-0ee0cf6af2a7>
 21. Methods for generating TLPs (typical load profiles) for smart grid-based energy programs | Request PDF - ResearchGate, fecha de acceso: septiembre 8, 2025,
https://www.researchgate.net/publication/252018844_Methods_for_generating_TLPs_typical_load_profiles_for_smart_grid-based_energy_programs
 22. Daily load profiles clustering: a powerful tool for demand side management in medium-sized industries - ACEEE, fecha de acceso: septiembre 8, 2025,
https://www.aceee.org/files/proceedings/2017/data/polopoly_fs/1.3687878.1501159057!/filesserver/file/790265/filename/0036_0053_000073.pdf
 23. Whitepaper: End uses of Load disaggregation - OurEnergyPolicy, fecha de

acceso: septiembre 8, 2025,

<https://www.ourenergypolicy.org/wp-content/uploads/2015/10/EndUsesOfLoadDissagregationv6.pdf>

24. A Two-Step Time-Series Data Clustering Method for Building-Level Load Profile - Publications, fecha de acceso: septiembre 8, 2025,
<https://docs.nrel.gov/docs/fy23osti/84634.pdf>
25. Smart Meters Time Series Clustering for Demand Response Applications in the Context of High Penetration of Renewable Energy Resources - MDPI, fecha de acceso: septiembre 8, 2025, <https://www.mdpi.com/1996-1073/14/12/3458>
26. Validating Clustering Frameworks for Electric Load Demand Profiles - arXiv, fecha de acceso: septiembre 8, 2025, <https://arxiv.org/pdf/2103.00030>
27. Generation of customer load profiles based on smart-metering time series, building-level data and aggregated measurements - CORE, fecha de acceso: septiembre 8, 2025, <https://core.ac.uk/download/pdf/83463004.pdf>
28. Time Series - ARIMA vs. SARIMA vs. LSTM: Hands-On Tutorial | Towards Data Science, fecha de acceso: septiembre 8, 2025,
<https://towardsdatascience.com/time-series-arima-vs-sarima-vs-lstm-hands-on-tutorial-bd5630298da3/>
29. MODELING AND FORECASTING SHORT-TERM ELECTRICITY LOAD USING REGRESSION ANALYSIS - Illinois State University, fecha de acceso: septiembre 8, 2025,
<https://irps.illinoisstate.edu/downloads/research/student/LoadForecastingHinman-HickeyFall2009.pdf>
30. Time series prediction using ARIMA vs LSTM - Data Science Stack Exchange, fecha de acceso: septiembre 8, 2025,
<https://datascience.stackexchange.com/questions/12721/time-series-prediction-using-arima-vs-lstm>
31. Analyzing Industrial Electricity Demand: Applying Modern Econometric Time-Series Techniques - ACEEE, fecha de acceso: septiembre 8, 2025,
https://www.aceee.org/files/proceedings/2001/data/papers/SS01_Panel1_Paper49.pdf
32. An Econometric Assessment of Electricity Demand in the United States Using Utility-specific Panel Data and the Impact of Retail Competition on Prices - ResearchGate, fecha de acceso: septiembre 8, 2025,
https://www.researchgate.net/publication/318232357_An_Econometric_Assessment_of_Electricity_Demand_in_the_United_States_Using_Utility-specific_Panel_Data_and_the_Impact_of_Retail_Competition_on_Prices
33. Modeling & Forecasting US Electricity Consumption - The International Association for Energy Economics, fecha de acceso: septiembre 8, 2025,
<https://www.iaee.org/en/publications/proceedingsabstractpdf.aspx?id=5424>
34. Commercial Buildings Energy Consumption Survey (CBECS) - EIA, fecha de acceso: septiembre 8, 2025,
<https://www.eia.gov/consumption/commercial/reports.php>
35. An Econometric Assessment of Electricity Demand in the United States Using Utility-specific Panel Data and the Impact of Retail Competition on Prices -

- IDEAS/RePEc, fecha de acceso: septiembre 8, 2025,
<https://ideas.repec.org/a/aen/journal/ej38-4-ros.html>
36. Standard Scenarios | Energy Systems Analysis - NREL, fecha de acceso: septiembre 8, 2025, <https://www.nrel.gov/analysis/standard-scenarios>
 37. Scenario analysis | ConocoPhillips, fecha de acceso: septiembre 8, 2025, <https://www.conocophillips.com/sustainability/managing-climate-related-risks/strategy/scenario-analysis/>
 38. IEA-ETSAP | Energy Systems Analysis, fecha de acceso: septiembre 8, 2025, <https://iea-etsap.org/>
 39. IEA, Net Zero by 2050.pdf - Department of Energy, fecha de acceso: septiembre 8, 2025, <https://www.energy.gov/sites/default/files/2021-12/IEA,%20Net%20Zero%20by%202050.pdf>
 40. Energy Projections, calculating long term energy demand | IAEA, fecha de acceso: septiembre 8, 2025, <https://www.iaea.org/topics/energy-projections>
 41. Ecuador and the IMF, fecha de acceso: septiembre 8, 2025, <https://www.imf.org/en/Countries/ECU>
 42. Nominal GDP - Investor Relations - Ministerio de Economía y Finanzas, fecha de acceso: septiembre 8, 2025, <https://ire.finanzas.gob.ec/s/r/crecimiento.php>
 43. Ecuador Interest Rate - Trading Economics, fecha de acceso: septiembre 8, 2025, <https://tradingeconomics.com/ecuador/interest-rate>
 44. Forecast reconciliation: A review - Rob J Hyndman, fecha de acceso: septiembre 8, 2025, https://robjhyndman.com/papers/hf_review.pdf
 45. Reconciling temporal hierarchies of wind power production with forecast-dependent variance structures - DTU Orbit, fecha de acceso: septiembre 8, 2025, <https://orbit.dtu.dk/files/353934556/10.4171-mag-172.pdf>
 46. Iterative Trace Minimization for the Reconciliation of Very Short Hierarchical Time Series, fecha de acceso: septiembre 8, 2025, <https://arxiv.org/html/2409.18550v2>
 47. Iterative proportional fitting - Wikipedia, fecha de acceso: septiembre 8, 2025, https://en.wikipedia.org/wiki/Iterative_proportional_fitting
 48. 17. Iterative Proportional Fitting - Data Science Topics, fecha de acceso: septiembre 8, 2025, <https://datascience.oneoffcoder.com/ipf.html>
 49. iterec Iterative heuristic cross-temporal forecast reconciliation - RDocumentation, fecha de acceso: septiembre 8, 2025, <https://www.rdocumentation.org/packages/FoReco/versions/0.2.6/topics/iterec>
 50. Total Losses in Power Distribution and Transmission Lines | EEP, fecha de acceso: septiembre 8, 2025, <https://electrical-engineering-portal.com/total-losses-in-power-distribution-and-transmission-lines-1>
 51. Estimation Of Technical Losses In A Distribution System - International Journal of Engineering Research & Technology, fecha de acceso: septiembre 8, 2025, <https://www.ijert.org/research/estimation-of-technical-losses-in-a-distribution-system-IJERTV2IS60937.pdf>